

강원대학교
첨단AI공학과

머신러닝2

- 다중 회귀분석(Simple) -

- 종속변수를 설명하기 위해서 두 개 이상의 독립변수가 사용되는 선형회귀모형을 다중선형 회귀모형이라 함

**[예제] 예금 유치액을 설명하는데 도움을 주는 요인으로
홍보비용 뿐만 아니라 직원수, 지점의 크기 등을 고려한
다면 더 정확한 정보를 얻을 수 있다.**

- 종속변수를 설명하기 위해서 두 개 이상의 독립변수가 사용되는 선형회귀모형을 다중선형 회귀모형이라 함


표본지점의 예금유치액

지점번호	홍보비용	직원수	예금유치액
1	40	15	87
2	50	20	108
3	30	14	69
4	60	22	135
5	70	30	148
6	60	24	132
7	30	16	73
8	60	20	128
9	20	14	50
10	80	32	170

Q) 홍보비용과 직원수가 예금유치액에 어떤 영향을 미치는가?


01 다중회귀 회귀(Multiple Linear Regression)

- 종속변수를 설명하기 위해서 두 개 이상의 독립변수가 사용되는 선형회귀모형을 다중선형 회귀모형이라 함





01 다중회귀 회귀(Multiple Linear Regression)

- 종속변수를 설명하기 위해서 두 개 이상의 독립변수가 사용되는 선형회귀모형을 다중선형 회귀모형이라 함




01 다중회귀 회귀(Multiple Linear Regression)

- 초평면에 대해 설명해야 함



- 수학, 국어, 그리고 IQ가 기말성적에 어떤 영향을 미치는가?



다중회귀선형모형

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_k x_{ik} + \varepsilon_i$$

회귀계수

독립변수

$$y_i = \beta_0 + \beta_1 x_{i1} + \varepsilon_i$$

회귀계수

독립변수

<단순선형회귀모형>

모형 : $y_i = \beta_0 + \beta_1 x_{i1} + \varepsilon_i$

가정 : $\varepsilon_i \sim iidN(0, \sigma^2)$

y = 예금유치액

x_{i1} = 홍보비용

회귀계수에 대한 정보 ?

<다중 선형회귀모형>

모형: $y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \varepsilon_i$

가정: $\varepsilon_i \sim iidN(0, \sigma^2)$

y = 예금유치액

x_{i1} = 홍보비용, x_{i2} = 직원수

<단순선형회귀모형>

모형 : $y_i = \beta_0 + \beta_1 x_{i1} + \varepsilon_i$

가정 : $\varepsilon_i \sim iidN(0, \sigma^2)$

<다중 선형회귀모형>

모형 : $y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \varepsilon_i$

가정 : $\varepsilon_i \sim iidN(0, \sigma^2)$


최소제곱법(OLS)은 회귀모형의

오차 제곱의 합 $SSE = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$ 을 최소로

하는 회귀계수를 이들의 추정치로 하는 것


01 다중회귀 회귀(Multiple Linear Regression)

홍보비용과 예금유치액에 대한 산점도



$$y = \beta_0 + \beta_1 x_1 + \varepsilon, \quad y = \text{예금유치액}, x_1 = \text{홍보비용}$$

$$\hat{y} = 10 + 2 \times \text{홍보비용}$$




01 다중회귀 회귀(Multiple Linear Regression)

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon$$


y = 예금유치액, x_1 =홍보비용, x_2 =직원수

홍보비용, 직원수 그리고
예금유치액에 대한 산점도



추정된 다중회귀모형

$$\hat{y} = 9.23 + 1.95 \times \text{홍보비용} + 0.15 \times \text{직원수}$$



다중회귀 코드

```
install.packages(" rstatix ") #통계 테스트
install.packages(" skimr ") #데이터의 흐름 요약

library(rstatix)
library(skimr)

#데이터 불러오기
df <- read.csv("diabetes.csv", header = TRUE, stringsAsFactors = TRUE)
skim(df)

#결측값 제거
df <- na.omit(df)

#불필요 변수 제거
df <- select(df, -c(var1)) #하나면 제거(순수한 열 이름만 적기)
df <- select(df, -c(var1, var2, var3)) #여러 개 제거
skim(df)
```

다중회귀 코드

#다중회귀분석

```
result <- lm(df$Diabetes ~ ., data = df)
```

```
result1 <- lm(df$Diabetes ~ 1, data = df) # 다른 변수 고려 x(단순 평균으로 예측)
```

#ANOVA분석을 활용해 두 집단의 의미있는 차이가 있는지 확인(잔차제곱합 차이의 검증)

```
anova_result <- anova(result1, result)
```

```
print(anova_result)
```

#회귀모델

```
summary(result)
```

#모델 저장

```
saveRDS(model, "regression_model.rds")
```

#모델 불러오기

```
loaded_model <- readRDS("regression_model.rds")
```

다중회귀 코드

```
#데이터를 csv에서 불러오기
new_data <- read.csv("diabetes_test.csv")

#모델에 새로운 데이터 추가
predicted<- predict(loader_model, newdata = new_data)
head(predicted)

#예측 결과 출력
results <- data.frame(new_data, Predicted = predicted)
```

다중회귀 코드

#RMSE 계산

```
rmse <- sqrt(mean((results$Diabetes - results$Predicted)^2))
```


```
print(paste("RMSE:", round(rmse, 3)))
```

모형의 타당성&신뢰성 검정


- 1) 선형성 → 예측하고자 하는 종속변수 y 와 독립변수 x 간의 선형성을 이루어야 함
- 2) 등분산성 → 오차의 분산이 같다는 것을 의미하고 특정한 패턴 없이 고르게 분포하는 것을 의미함
- 3) 독립성 → 오차 사이에는 서로 영향을 주지 않으며 오차간의 상관 없이 독립적이어야 함
- 4) 정규성 → 잔차가 정규성을 만족하는지 여부 (오차가 평균이 0인 정규분포)
- 5) 다중공선성 → 회귀 모델에서 두 개 이상의 독립변수가 서로 높은 상관관계가 있는 상황

01 다중회귀 회귀(Multiple Linear Regression)

- 1) 선형성 → 예측하고자 하는 종속변수 y 와 독립변수 x 간의 선형성을 이루어야 함



선형성 만족 O



선형성 만족 X

- 1) 선형성 → 예측하고자 하는 종속변수 y 와 독립변수 x 간의 선형성을 이루어야 함


```
Fitted <- fitted(result)      # 적합값
Residuals <- resid(result)    # 잔차

library(ggplot2)

ggplot(df, aes(x = Fitted, y = Residuals)) +
  geom_point(alpha = 0.6) +
  geom_smooth(method = "loess", se = FALSE, color = "blue") +
  geom_hline(yintercept = 0, linetype = "dashed", color = "red") +
  labs(title = "Residuals vs Fitted (선형성 확인)",
       x = "적합값 (Fitted values)",
       y = "잔차 (Residuals)") +
  theme_minimal()
```

01 다중회귀 회귀(Multiple Linear Regression)


- 1) 선형성 → 예측하고자 하는 종속변수 y 와 독립변수 x 간의 선형성을 이루어야 함




01 다중회귀 회귀(Multiple Linear Regression)

- 2) 등분산성 → 잔차의 분산이 같다는 것을 의미하고 특정한 패턴 없이 고르게 분포하는 것을 의미함


잔차의 패턴이 없음




(a)




(b)



(c)



(d)



(e)

- 다트 게임에서 항상 같은 거리에서 던지면, 명중점들이 과녁 주위에 비슷한 폭으로 흩어짐 = 등분산
- 수산물 시장에서 항목별로 무게가 달라진다. (무거울수록 오차가 점점 커지면 이분산)

- 2) 등분산성 → 잔차의 분산이 같다는 것을 의미하고 특정한 패턴 없이 고르게 분포하는 것을 의미함

```
StdResid <- sqrt(abs(df$Residuals)) # 표준화된 잔차의 크기 근사치
```


```
ggplot(df, aes(x = Fitted, y = StdResid)) +  
  geom_point(alpha = 0.6) +  
  geom_smooth(method = "loess", se = FALSE, color = "blue") +  
  labs(title = "Scale-Location Plot (등분산성 확인)",  
        x = "적합값 (Fitted values)",  
        y = "Standardized Residuals") +  
  theme_minimal()
```

#등분산성 : $p > 0.05$ 보다 크면, 등분산성 가정을 유지 $\longleftrightarrow$ 반대는 이분산성

```
library(lmtest)  
bptest(result)
```

01 다중회귀 회귀(Multiple Linear Regression)

- 2) 등분산성 → 잔차의 분산이 같다는 것을 의미하고 특정한 패턴 없이 고르게 분포하는 것을 의미함



01 다중회귀 회귀(Multiple Linear Regression)

- 3) 독립성 → 잔차 사이에는 서로 영향을 주지 않으며 잔차간의 상관 없이 독립적이어야 함
 - 버스가 지연되면 다음 정거장 도착도 연쇄적으로 지연됨 → 잔차(+지연)가 줄줄이 이어짐 = 독립성 위반
 - 현실 예(집단): 같은 반 학생들의 시험 채점에서, 채점량이 많아 피곤해 이후의 시험에 점수를 후하게/박하게 = 독립성 위반
- Durbin Watson 검정
 - 검정통계량 D-W Statistic 값이 0~4의 값을 가지며 0으로 가까울 수록(잔차의) 양의 상관관계 4에 가까울수록 음의 상관관계
 - 1.5~2.5사이 일때 잔차는 독립
 - 0 근사 : 양의 자기상관
 - 4 근사 : 음의 자기상관

#독립성 : $p > 0.05$ 보다 크면 잔차의 독립성을 가짐

```
library(car)  
durbinwatsonTest(result)
```

- 4) 정규성 → 잔차가 정규성을 만족하는지 여부 (잔차가 정규성을 만족하면 잔차가 평균이 0)

샤피로 윌크 검정(Shapiro-Wilk test) : 표본수가 2,000미만인 데이터셋에 적합한 정규성 검정

스미르노프 검정(Kolmogorov-Smirnov test) : 표본수가 2,000초과인 데이터셋에 사용


Quantile-Quantile plot(Graphic test) : 데이터셋이 정규분포를 따르는지 판단하는 시각적 분석방법 (Qqplot)
→ Z-Score : 잔차/표준편차

- 4) 정규성 가설검정

정규성 검정에 대한 p-value : 0.05보다 크면 귀무가설 채택

Null hypothesis(H_0 ; 귀무가설) : 잔차가 정규분포를 따름

Alternative hypothesis(H_1 ; 대립가설) : 잔차가 정규분포를 따르지 않음



ShapiroResult(statistic=0.9721834659576416, pvalue=0.9044272899627686)

- 4) 정규성 가설검정


```
#정규성 : p>0.05보다 크면 귀무가설 채택(정규성이 있음)  
shapiro_test(result$residuals)
```

```
#4개의 조건에 대한 그래프를 모두 보는 방법  
opar <- par(no.readonly = TRUE) # 그래프가 들어갈 window 생성  
par(mfrow = c(2, 2)) # 그래프가 들어갈 공간 생성 2x2  
plot(result) # 그래프 결과 도출  
par(opar) # 그래픽 매개변수 복원
```


01 다중회귀 회귀(Multiple Linear Regression)

- 가정 검증

선형성
잔차의 평균이 0 부근에서 평평한지



표준화 잔차의 크기




잔차의 정규성


기대위치에 대한 표준화 잔차 값

루트 표준화 잔차의 크기

등분산성



표준화 잔차의 크기



모델을 크게 흔드는 이상치를 판단

01 다중회귀 회귀(Multiple Linear Regression)


- 이상치 제거

X축 : 독립 변수의 값이 모든 값의 평균에서 얼마나 떨어져 있는가?

Y축 : 관찰값과 예측된 값 상의 떨어져 있는 표준편차

데이터의 크기 : 회귀 모델에 영향을 크게 주는 것(하나의 데이터가 너무 크면 문제)

표준화 잔차(얼마나 틀렸나)와 레버리지(얼마나 특이한 위치인가)



- 이상치 제거

```
#이상치검정 : cook's D 값이 높으면 문제
#세 기준에서(StudRes, Hat CookD) 상위 3개를 각각 뽑아 합친 것
cand <- influencePlot(result, id = list(n = 3))

mf <- model.frame(result) # 모형에 실제로 쓰인 데이터 (결측 제외된 상태)
z <- round(scale(mf[sapply(mf, is.numeric)]), 1)

rownames(z) <- rownames(mf) # 행 이름을 다시 붙임
cbind(round(cand, 2), z[rownames(cand), ])
```

01 다중회귀 회귀(Multiple Linear Regression)

- 이상치 제거

스튜던트화 잔차 (Studentized) → 잔차/(해당 데이터의 점을 뺀 나머지로 추정된 오차 표준편차) → 즉, 오차의 이탈도(얼마나 틀렸나)

	StudRes	Hat	CookD	df\$Diabetes	Glucose	SkinThickness	Insulin
5	5.49	0.00	0.02	5.5	0.5	0.9	0.8
14	-1.14	0.07	0.02	-0.2	2.1	0.2	6.6
229	5.00	0.05	0.30	5.6	2.4	1.2	5.8
371	4.53	0.02	0.08	5.0	1.6	1.7	3.3
446	5.71	0.02	0.19	5.9	1.8	2.7	-0.6
580	-0.57	0.06	0.01	0.3	2.4	4.9	-0.7

CookD : 값이 0.5미만이면 모형을 흔드는 값이 없음(이상없음), 1에 가까울 수록 이상

Cook's D < 0.5 → 영향점 없음, 0.5~1 → 확인, > 1 → 영향점

- 이상치 제거

#이상치 제거

```
out_rows <- c("108", "121", "145", "160", "277") #확인 후 직접 입력  
df2 <- df[!rownames(df) %in% out_rows, ]
```

#이상치가 제거된 데이터로 다시 분석 및 그래프 추출

```
result2 <- lm(Diabetes ~ ., data = df2)  
cand <- influencePlot(result2, id = list(n = 3))
```

#max Cook's D < 0.5 → 영향점 없음, 0.5~1 → 확인, > 1 → 영향점
max(cooks.distance(result2))


모형의 타당성&신뢰성 검정

- 5) 다중공선성 → 회귀 모델에서 두 개 이상의 독립변수가 서로 높은 상관관계가 있는 상황
→ 고차항과 원변수는 수학적으로 강한 상관성을 가짐
- 독립변수들간의 상관관계가 높을 경우, 회귀계수의 값이 매우 커지는 문제
- 회귀계수의 변동성이 커져서 통계량과 모수가 서로 반대 부호를 가질 수 있음
- 분산팽창계수 : Variance Inflation Factor
 - $VIF = \frac{1}{1-R^2}$

01 다중회귀 회귀(Multiple Linear Regression)

독립 변수의 일부가 다른 독립 변수의 조합으로 표현될 수 있는 경우

VIF 지수가 10이상일 때 연관성이 있다고 판단 → R-Squared값이 유지되거나 높아지는 모델을 찾아야 함



- 5) 다중공선성

```
#다중공선성(변수의 중복성) : 10이상 GVIF^(1/(2*DF))  
vif_values <- vif(result)
```

```
print(vif_values)  
#그래프와 상관계수를 그려주는 것이 좋을거 같음
```

```
selected_predictors <- names(vif_values[vif_values > 7]) #서로가 영향을 주는  
변수 추출 후 임의로 제거 필요  
print(selected_predictors)
```

01 다중회귀 회귀(Multiple Linear Regression)

- **AIC(Akaike information criterion)를 활용한 변수선택** → $AIC = -2 \times \log - likelihood + 2 \times k$
k = 추정한 파라미터 개수
- 모형 적합도(log-likelihood) 와 모형 복잡도(변수 개수) 를 동시에 고려하는 지표 → 절대적인 임계값이 없음
- AIC는 로그우도(log-likelihood)와 모형 복잡도를 합친 지표 → 값이 절대적으로 몇 이상이면 나쁘다/좋다라고 정할 수 없음
- 단순히 AIC값이 작을수록 좋은 모델이라는 상대적 기준만 존재

```
df <- read.csv("diabetes.csv", header = TRUE, na = ".")
```

```
result <- lm(df$Diabetes ~ ., data = df)
```

01 다중회귀 회귀(Multiple Linear Regression)

- 변수선택

AIC(Akaike information criterion) AIC값이 줄어들면 그 변수는 의미가 있음

```
library("MASS")
```

```
#후진소거법
```

```
result_bk = lm(df$Diabetes ~., data=df)
```

```
Df_fit_bk = stepAIC(result_bk, direction= "backward" , trace = T) #trace 하나씩 빼는 과정을 보여줌
```

```
#단계적선택법
```

```
Df_fit_st = stepAIC(result_bk, direction = "both", trace = T)
```

```
#전진선택법
```

```
result_fw = lm(df$Diabetes ~ 1, data=df)
```

```
Df_fit_fk = stepAIC(result_fw, direction= "forward", scope = (backward 변수 카피) , trace = T)
```